

# Permanenze nelle strutture alberghiere portoghesi

Beatrice Malvezzi, 907500

Metodi statistici per il turismo: modelli e applicazioni - a.a. 2023/2024

## 1 Introduzione

Il file *permanenze.csv* contiene la serie storica del numero di notti trascorse nelle strutture alberghiere in alcuni paesi europei nel periodo gennaio 2010 – marzo 2024 (fonte: *EURO-STAT*).

Gli obiettivi dell'analisi sono descrivere l'andamento e le componenti della serie storica tramite grafici e indici statistici, stimare un modello adeguato a spiegare come il valore corrente dipenda dal passato e fare una previsione per descrivere quale andamento avrebbe avuto la serie se non ci fosse stata l'epidemia di Covid-19.

Si è selezionato il Portogallo come paese europeo su cui svolgere l'analisi.

Il dataset contiene 171 osservazioni (righe) e 2 variabili (colonne).

L'unità di osservazione è il mese. Le due variabili sono:

- *Mese*: riferimento temporale, mese e anno (chr),
- *Portugal*: numero di notti trascorse nelle strutture alberghiere portoghesi (int)

Per poter studiare il dataset è necessario trasformare la variabile *Mese*, di tipo character, in data tramite la funzione *as.POSIXct* ed esprimere la variabile *Portugal* secondo un'unità di misura adeguata alla rappresentazione grafica. Si è scelta come scala il milione.

È necessario inoltre applicare la funzione *ts* per far sì che R riconosca i dati come una serie storica.

## 2 Analisi descrittive

Uno studio preliminare della serie può essere svolto tramite grafici e statistiche descrittive.

A partire dal *Time-Series Plot* (Fig. 1) è possibile osservare l'andamento della serie storica. Si può notare un incremento costante nel tempo delle permanenze nelle strutture alberghiere fino ai primi mesi del 2020, in cui si può notare l'impatto dell'epidemia di Covid-19.

È possibile anche notare un picco di permanenze durante il mese di agosto di ogni anno, che suggerisce la presenza di stagionalità.




Fig. 1: Time-Series Plot (gennaio 2010 – marzo 2024)

Per poter evidenziare la componente stagionale si utilizzano il *Seasonal Plot* (Fig. 2) e il *Polar Graph* (Fig. 3). Il primo rappresenta ogni anno come una spezzata ponendo sull'asse delle ascisse i periodi stagionali mentre il secondo si serve delle coordinate polari, ovvero un sistema di coordinate bidimensionali in cui ciascuna osservazione è determinata dalla distanza dal punto di riferimento, che corrisponde all'intensità del fenomeno, e dall'angolo che determina la direzione. Nel caso in esame la direzione è data dal mese mentre il punto di riferimento è il numero di notti trascorse nelle strutture alberghiere portoghesi.

Entrambi i grafici sono un'ulteriore conferma di quanto ipotizzato in precedenza, ossia che è presente una stagionalità annuale e che il numero di notti trascorse nelle strutture alberghiere è in aumento con un picco massimo durante il mese di agosto. Si può notare anche in questo caso una variazione per gli anni 2020 e 2021.




Fig. 2: Seasonal Plot




Fig. 3: Polar Graph

Tramite il calcolo di indici descrittive è possibile ricavare informazioni aggiuntive quali la media (4.9202), la mediana (4.3255), il minimo della serie (0.1517), che si è raggiunto durante il mese di aprile 2020, e il massimo (12.1764), corrispondente al mese di agosto 2023.

La varianza della serie storica ha un valore abbastanza elevato, pari a 6.912811, a causa dell'effetto dell'epidemia di Covid-19.

Si possono inoltre ricavare i grafici dell'autocovarianza (Fig. 4) e dell'autocorrelazione (Fig. 5) per i diversi lag. Essi rappresentano l'associazione e il legame lineare tra osservazioni all'interno di una stessa serie storica equidistanti nel tempo. I due grafici si distinguono per la scala.

Si osserva un andamento oscillatorio; in particolare in riferimento alla Fig. 5 si può affermare che c'è un'alternanza tra una debole associazione positiva (es. valori da lag 1 a lag 3) e negativa (es. valori da lag 4 a lag 8).




Fig. 4: Grafico dell'autocovarianza




Fig. 5: Grafico dell'autocorrelazione

Si osserva una forte associazione positiva per quanto riguarda il valore di lag 12 e i suoi multipli. Significa che il valore al tempo  $t$  è fortemente correlato con quello relativo ai 12 mesi precedenti (es. gennaio 2014 è fortemente correlato con gennaio 2013).

Il passo è pari a quello della stagionalità, quindi ribadisce ancora una volta la sua presenza.

### 3 Decomposizione della serie storica

Dato che le variazioni stagionali aumentano nel tempo (Fig. 1), si decompone la serie storica nelle sue componenti di trend, stagionalità e accidentalità (o termine di errore) attraverso il modello moltiplicativo.

Il primo grafico che si ottiene (Fig. 6) rappresenta l'andamento della serie; infatti, è il medesimo riportato nella Fig. 1. Il secondo si riferisce al trend ed esprime una tendenza crescente nel tempo fino ai primi mesi del 2020 in cui si verifica una decrescita molto forte, seppur temporanea.

Nel terzo grafico è rappresentata la componente stagionale, risulta molto regolare con un'alternanza di picchi positivi e negativi.

Infine, l'ultimo grafico rappresenta l'accidentalità. Si presenta con una scala molto inferiore rispetto a quella della stagionalità a parte per i mesi influenzati dall'epidemia di Covid-19.




Fig. 6: Decomposizione della serie storica

#### 4 Modello per la dipendenza dal passato

Si procede lo studio della serie storica considerando il periodo gennaio 2010 – dicembre 2019 (120 osservazioni).

Prima di stimare un modello che spieghi come il valore corrente dipenda dal passato è necessario verificare che la serie sia stazionaria in media e in varianza.

Osservando il Time-Series Plot (Fig. 7), si può affermare che la serie non è stazionaria in media in quanto presenta un trend crescente o, in altre parole, la spezzata non oscilla attorno al valor medio, riportato in rosso sul grafico. La serie non è neanche stazionaria in varianza poiché il range di oscillazioni non è costante nel tempo ma aumenta.




Fig. 7: Time-Series Plot (gennaio 2010 – dicembre 2019)

Per rendere la serie stazionaria in varianza, si può usare la *trasformazione di Box-Cox*, che in questo caso suggerisce di applicare una trasformazione logaritmica ( $\lambda = 0$ ).

Secondariamente, si rende la serie storica stazionaria in media usando le differenze stagionali e di ordine 1. Il risultato è la serie stabilizzata (Fig. 8), composta da un totale di 107 osservazioni siccome se ne perdono 13, di cui 12 per la differenziazione stagionale e 1 e per la differenziazione di ordine 1.




Fig. 8: Serie storica stazionaria

Tramite i grafici dell'autocorrelazione (Fig. 9) e dell'autocorrelazione parziale (Fig. 10), si possono identificare i parametri del modello.

Per la parte a media mobile si individuano i parametri  $q = 1$  e  $Q = 1$  come parametro per la stagionalità (Fig. 9). Per la parte autoregressiva si ipotizzano i valori  $p = 2$  e  $Q = 2$  per la stagionalità (Fig. 10).




Fig. 9: Grafico dell'autocorrelazione




Fig. 10: Grafico dell'autocorrelazione parziale

Si verifica se il modello con i parametri individuati è adeguato sovrapponendo i valori fittati (linea rossa tratteggiata) con i veri valori della serie (linea nera). Si nota che le due linee non coincidono (Fig. 11), di conseguenza il modello scelto non sembra essere adeguato poiché sono presenti deviazioni non trascurabili.

Come ulteriore conferma è possibile svolgere un'analisi dei residui tramite il comando *checkresiduals* (Fig. 12). I residui hanno approssimativamente media nulla e distribuzione normale, tuttavia non viene verificata l'ipotesi di incorrelazione per i lag 12 e 13.

È necessario quindi identificare un modello con un adattamento migliore.




Fig. 11: Modello reale con valori fittati




Fig. 12: Analisi dei residui

La funzione *auto.arima*, contenuta nel pacchetto *forecast*, permette di identificare i parametri automaticamente andando a scegliere il modello che minimizza l'Aikake Information Criterion corrected (AICc). Si ottiene il modello  $ARIMA(0, 0, 1)(2, 1, 1)[12]$ .

Dal grafico (Fig. 13) si osserva un buon adattamento del modello a parte per piccole deviazioni trascurabili. Rimane qualche autocorrelazione tra gli errori (Fig. 14) a causa degli effetti stagionali, seppur trascurabile.

Complessivamente si può affermare che le assunzioni siano verificate, ossia che i residui sono centrati sullo zero, hanno distribuzione normale e non sono autocorrelati.




Fig. 13: Time-Series Plot con valori fittati




Fig. 14: Analisi dei residui

## 5 Previsioni

È possibile utilizzare il modello appena definito per prevedere il valore della serie storica per il periodo gennaio – settembre 2020. La previsione permette di osservare quale andamento avrebbe avuto la serie se non ci fosse stata l'epidemia di Covid-19.

Tramite la funzione *forecast* si calcolano una stima puntuale e due stime intervallari di livelli 80% e 95% per i primi 9 mesi del 2020.

Il grafico sottostante (Fig. 15) rappresenta l'andamento della serie con l'aggiunta della previsione fatta. Si può notare che la previsione è in linea con i valori storici, con una tendenza crescente, diversamente dai valori effettivi che indicano un forte calo del turismo nel periodo considerato (Fig. 1).




Fig. 15: Serie prevista

## 6 Conclusioni

Per riassumere, l'analisi della serie storica si è svolta tramite un iniziale studio di grafici relativi alla stagionalità e statistiche descrittive al fine di comprenderne l'andamento complessivo.

Si è notato un aumento delle permanenze nelle strutture alberghiere portoghesi nel corso del tempo, con un'eccezione a partire dai primi mesi dell'anno 2020, sui quali ha influito l'inizio



dell'epidemia di Covid-19. La presenza di picchi durante i mesi di agosto di ogni anno ha permesso di ipotizzare la presenza di stagionalità.

Per gli studi successivi si è utilizzata la serie relativa al periodo gennaio 2010 – dicembre 2019, ovvero escludendo il periodo influenzato dall'effetto Covid-19.

Si è osservato che la serie non è stazionaria in media e in varianza, di conseguenza sono state applicate la trasformazione Box-Cox per stabilizzarla in varianza, la differenziazione stagionale di lag 12 e la differenziazione di ordine 1 per stabilizzarla in media.

Tramite i grafici di autocorrelazione e autocorrelazione parziale si sono ipotizzati dei valori per la parte a media mobile del modello ( $q = 1$ ,  $Q = 1$ ) e per la parte autoregressiva ( $p = 2$ ,  $P = 2$ ). Tuttavia, il modello stimato non è risultato adeguato poiché i valori fittati non coincidevano con quelli osservati e non venivano soddisfatte pienamente le assunzioni sui residui.

Tramite la funzione *auto.arima* si è individuato un modello ARIMA(0, 0, 1)(2, 1, 1)[12] che ha dimostrato avere un miglior adattamento.

Il modello stimato è stato utilizzato per ricavare la previsione per il periodo gennaio – settembre 2020, con lo scopo di descrivere quale andamento avrebbe avuto la serie se non ci fosse stata l'epidemia di Covid-19.

### **Dichiarazione di lavoro autonomo**

*Con la sottomissione del paper riconosco che il contenuto (se non diversamente indicato usando citazioni) e il codice R sono stati sviluppati solo da me.*

03/06/2024,

*Beatrice Malvezzi*